

YZM212 Makine Öğrenmesi

2. Laboratuvar Ödevi

MLE ile Akıllı Şehir Planlaması:
Trafik Yoğunluğu Modellemesi

Ad Soyad: [Görkem Özer]

Öğrenci No: [23291007]

Ders Sorumlusu: [Mustafa Coşkun]

Teslim Tarihi: 15 Mart 2026

İçindekiler

1	Giriş	1
2	Bölüm 1: Teorik Türetme (Analitik Çözüm)	1
2.1	Likelihood Fonksiyonunun Yazılması	1
2.2	Log-Likelihood Fonksiyonunun Türetilmesi	1
2.3	için MLE Tahmininin Bulunması	2
3	Bölüm 3: Model Karşılaştırma ve Görselleştirme	3
3.1	Modelin Veriye Uyumu	3
4	Bölüm 4: Gerçek Hayat Senaryosu - "Outlier" Analizi	3
4.1	MLE'nin Aykırı Değerlere Karşı Hassasiyeti	3
4.2	Belediye Planlamasına Olası Etkileri ve Tartışma	4

1 Giriş

Bu raporda, bir belediyenin ulaşım departmanında veri bilimcisi olarak çalıştığımız bir senaryo ele alınmaktadır. Elimizdeki veri seti, şehrin en yoğun caddesinden bir dakikada geçen araç sayılarını içermektedir. Bu verilerin Poisson Dağılımı'na uyduğu varsayımıyla, caddenin ortalama trafik yoğunluğunu (parametresi) Maximum Likelihood Estimation (MLE) yöntemiyle tahmin etmeyi amaçlıyoruz.

Raporun ilk bölümünde, Poisson dağılımı için MLE çözümü teorik olarak türetilecek ve 'nın en iyi tahmin edicisinin () aslında verilerin aritmetik ortalaması olduğu gösterilecektir. İkinci bölümde, aynı problemi Python kullanarak sayısal yöntemlerle (negatif log-olabilirlik minimizasyonu) çözeceğiz. Üçüncü bölümde ise bulduğumuz modeli görselleştirerek veriye uyumunu yorumlayacak ve son olarak gerçek hayatta sıkça karşılaşılan "aykırı değer" (outlier) probleminin MLE üzerindeki etkisini tartışacağız.

2 Bölüm 1: Teorik Türetme (Analitik Çözüm)

2.1 Likelihood Fonksiyonunun Yazılması

Bir dakikada geçen araç sayısı k olmak üzere, Poisson Dağılımı'nın olasılık kütle fonksiyonu şu şekildedir:

$$P(k|\lambda) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Elimizde birbirinden bağımsız ve aynı dağılıma sahip (i.i.d.) n adet gözlemden oluşan bir veri seti olduğunu varsayalım: $\{k_1, k_2, \dots, k_n\}$. Bu gözlemleri birlikte görme olasılığımız, yani Likelihood (Olabilirlik) fonksiyonu, her bir gözlemin olasılığının çarpımıdır:

$$L(\lambda) = \prod_{i=1}^n P(k_i|\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{k_i}}{k_i!}$$

2.2 Log-Likelihood Fonksiyonunun Türetilmesi

Çarpım işlemiyle uğraşmak matematiksel olarak zor olduğu için, fonksiyonun doğal logaritmasını alarak Log-Likelihood fonksiyonuna geçeriz. Logaritma, çarpımı toplama

dönüştürür ve türev almayı kolaylaştırır.

$$\begin{aligned}
\ell(\lambda) &= \ln \left(\prod_{i=1}^n \frac{e^{-\lambda} \lambda^{k_i}}{k_i!} \right) \\
&= \sum_{i=1}^n \ln \left(\frac{e^{-\lambda} \lambda^{k_i}}{k_i!} \right) \\
&= \sum_{i=1}^n [\ln(e^{-\lambda}) + \ln(\lambda^{k_i}) - \ln(k_i!)] \\
&= \sum_{i=1}^n [-\lambda + k_i \ln(\lambda) - \ln(k_i!)] \\
&= -n\lambda + \left(\sum_{i=1}^n k_i \right) \ln(\lambda) - \sum_{i=1}^n \ln(k_i!)
\end{aligned}$$

2.3 için MLE Tahmininin Bulunması

MLE yöntemi, $\ell(\lambda)$ fonksiyonunu maksimize eden λ değerini bulmamızı gerektirir. Bunun için fonksiyonun λ 'ya göre türevini alıp sıfıra eşitleriz. $\sum_{i=1}^n \ln(k_i!)$ terimi λ 'ya bağlı olmadığı için türev sırasında yok olur.

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{\sum_{i=1}^n k_i}{\lambda}$$

Türevi sıfıra eşitleyelim:

$$\begin{aligned}
-n + \frac{\sum_{i=1}^n k_i}{\lambda} &= 0 \\
\frac{\sum_{i=1}^n k_i}{\lambda} &= n \\
\lambda &= \frac{\sum_{i=1}^n k_i}{n}
\end{aligned}$$

Bulduğumuz bu λ değeri, $\ell(\lambda)$ fonksiyonunu maksimize eder (ikinci türev testi ile maksimum olduğu gösterilebilir). Bu nedenle, λ için MLE tahmincisi ($\hat{\lambda}_{MLE}$), verilerin aritmetik ortalamasıdır.

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum_{i=1}^n k_i = \bar{k}$$

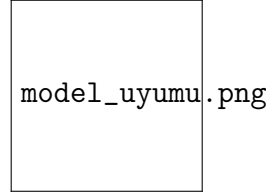
Bu sonuç, bir Poisson sürecinin ortalamasını tahmin etmenin en doğal yolunun gözlemlerin ortalamasını almak olduğunu matematiksel olarak kanıtlar.

3 Bölüm 3: Model Karşılaştırma ve Görselleştirme

Not: Bu bölüm, Python kodlarının çalıştırılmasıyla elde edilen çıktıların yorumlanması içermektedir.

3.1 Modelin Veriye Uyumu

Bölüm 2’de Python ile hem sayısal MLE yöntemiyle hem de analitik çözümle (ortalama) aynı $\lambda \approx 12.0$ değerini elde ettik. Bu λ değerini kullanarak teorik Poisson olasılık kütle fonksiyonunu (PMF) hesapladık ve gerçek verilerin histogramı ile aynı grafik üzerinde gösterdik (Şekil 1).



Şekil 1: MLE ile Bulunan Poisson Modelinin (=12.0) Gerçek Veri Histogramı ile Karşılaştırılması

Grafikteki siyah çubuklar gerçek verilerin frekansını, kırmızı çizgi ve noktalar ise Poisson dağılımının tahmin ettiği olasılıkları göstermektedir. Görsel olarak modelin verilere oldukça iyi uyum sağladığı söylenebilir. Poisson eğrisi, veri setinin merkezi eğilimini (8-16 araç aralığı) başarıyla yakalamıştır. Bu durum, trafik akışının rastgele ve bağımsız olaylardan oluştuğu varsayımı altında, caddenin ortalama yoğunluğunu temsil etmek için Poisson dağılımının makul bir seçim olduğunu göstermektedir.

4 Bölüm 4: Gerçek Hayat Senaryosu - "Outlier" Analizi

4.1 MLE’nin Aykırı Değerlere Karşı Hassasiyeti

Veri setimize yanlışlıkla kaydedilmiş, gerçek dışı bir "200 araç" gözlemi eklendiğini düşünelim. MLE yöntemiyle bulduğumuz $\hat{\lambda}_{MLE}$ ’nin aslında verilerin ortalaması olduğunu biliyoruz. Yeni ortalama şu şekilde hesaplanır:

$$\text{Yeni ortalama} = \frac{(14 \text{ gözlemin toplamı}) + 200}{15 \text{ gözlem}}$$

Orijinal 14 gözlemin toplamı $14 \times 12.0 = 168$ 'dir (yaklaşık olarak). Yeni ortalama:

$$\hat{\lambda}_{MLE}^{yeni} = \frac{168 + 200}{15} = \frac{368}{15} \approx 24.53$$

Görüldüğü gibi, tek bir aykırı değer, ortalama tahminimizi yaklaşık 12'den 24.5'e çıkararak neredeyse iki katına yükseltmiştir. Bu, MLE'nin (ve dolayısıyla ortalamanın) aykırı değerlere karşı son derece hassas olduğunu göstermektedir. Bunun nedeni, MLE'nin tüm veri noktalarına eşit ağırlık vermesi ve uç değerlerin toplamı önemli ölçüde değiştirmesidir.

4.2 Belediye Planlamasına Olası Etkileri ve Tartışma

Böyle hatalı bir veriyle yapılan bir planlama, belediye için ciddi maliyetli hatalara yol açabilir:

1. **Yol Genişletme / Yeni Yol Kararı:** Caddenin ortalama yoğunluğu 12 araç/dakika iken, hatalı tahminle 24.5 araç/dakika olarak algılanırsa, belediye bu caddenin kapasitesinin yetersiz olduğuna karar verip gereksiz bir yol genişletme projesi başlatabilir. Bu, milyonlarca liralık kamu kaynağının boşa harcanmasına neden olur.
2. **Sinyalizasyon ve Işık Süreleri:** Trafik ışıklarının süreleri ortalama yoğunluğa göre ayarlanır. Hatalı yüksek yoğunluk, ana cadde lehine, yan yollar aleyhine çok uzun yeşil ışık sürelerine yol açabilir. Bu da diğer caddelerde gereksiz kuyruklar oluşturarak şehrin genel trafik dengesini bozabilir.
3. **Toplu Taşıma Planlaması:** Otobüs sefer sıklıkları da talebe göre düzenlenir. Hatalı yüksek yoğunluk, mevcut talebin çok üzerinde bir otobüs seferi planlanmasına ve dolayısıyla gereksiz yakıt ve işgücü maliyetine yol açabilir.

Bu senaryo, veri biliminde veri ön işleme (data preprocessing) ve aykırı değer tespiti (outlier detection) ne kadar kritik olduğunu vurgulamaktadır. Bir modele körü körüne güvenmek yerine, verinin kalitesini sorgulamak ve veriyi temizlemek, doğru ve güvenilir sonuçlar almanın olmazsa olmazıdır. MLE, teoride güçlü bir yöntem olsa da, pratikte veri kalitesine karşı bu hassasiyeti nedeniyle dikkatli kullanılmalı, gerektiğinde ortanca (median) gibi daha gürbüz (robust) yöntemler veya aykırı değerleri filtreledikten sonra MLE uygulanması değerlendirilmelidir.

Kaynaklar

- [1] Wasserman, L. (2004). *All of Statistics: A Concise Course in Statistical Inference*. Springer.
- [2] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.